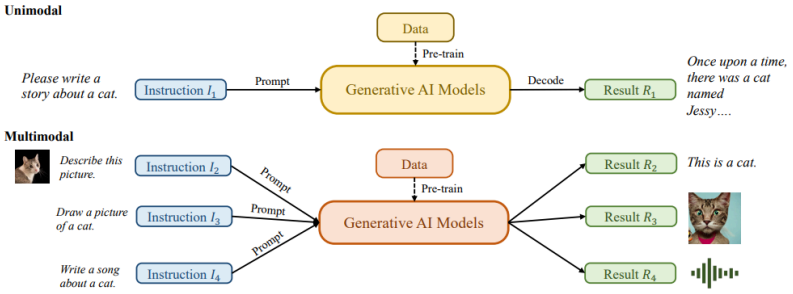
IPD440 - APRENDIZAJE DE MAQUINAS

Clase 15: Multimodal learning

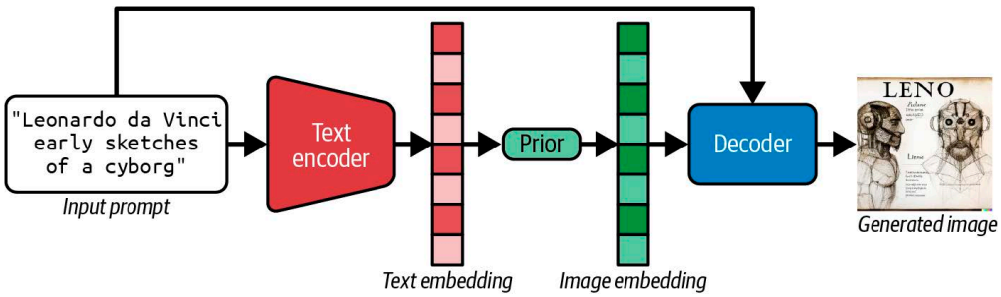
Prof. Nicolás Torres
nicolas.torresr@usm.cl
Ingeniería Civil Telemática
Departamento de Electrónica
Universidad Técnica Federico Santa María

Multimodal learning

Como seres humanos, no tenemos dificultades para cruzar modalidades: por ejemplo, imaginar un mundo de fantasía ficticio de un libro. El aprendizaje multimodal implica entrenar modelos generativos para convertir entre dos o más tipos diferentes de datos. Algunos de los modelos generativos más impresionantes introducidos en los últimos dos años han sido de naturaleza multimodal.

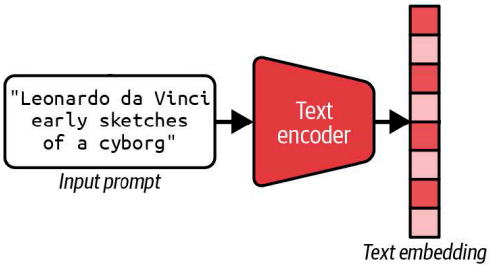


DALL·E 2



The Text Encoder

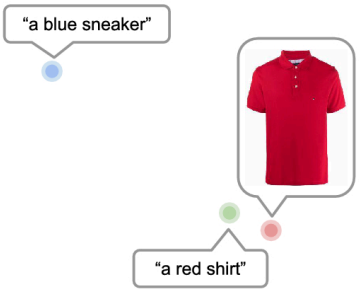
El objetivo del codificador de texto es convertir el prompt en un vector que represente el significado conceptual del mensaje dentro de un espacio latente.



En DALL·E 2, los autores no entrenan el codificador de texto desde cero, sino que utilizan un modelo existente llamado Contrastive Language–Image Pre-training (CLIP), también producido por OpenAI. Por lo tanto, para comprender el codificador de texto, primero debemos comprender cómo funciona CLIP.

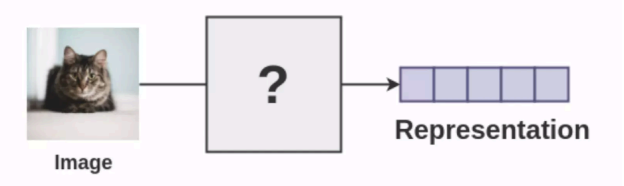
CLIP: Connecting text and images

CLIP (Contrastive Language-Image Pre-Training) es una red neuronal que aprende conceptos visuales de manera eficiente a partir de la supervisión del lenguaje natural. Utiliza una técnica llamada aprendizaje contrastivo para unir imágenes con descripciones de texto.



Contrastive Learning

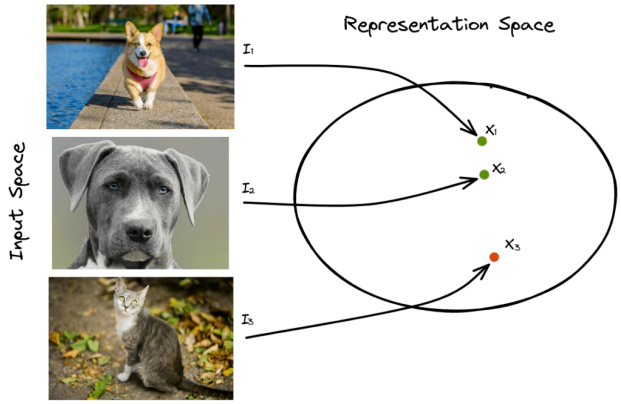
El aprendizaje contrastivo busca aprender representaciones útiles de datos, maximizando la similitud entre muestras similares y minimizando la similitud entre muestras diferentes.





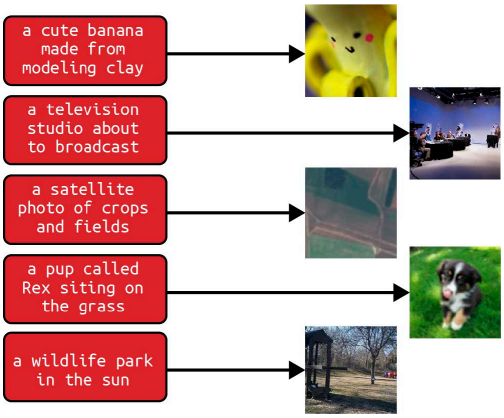
Representation space

Se contrastan muestras similares y diferentes. Específicamente, se intenta acercar muestras similares entre sí en el espacio de representación y alejar las diferentes.



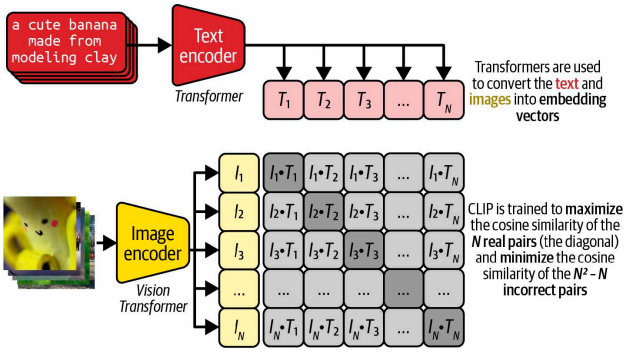
Text–image pairs

El modelo se entrena con un conjunto de datos de 400 millones de pares texto–imagen.



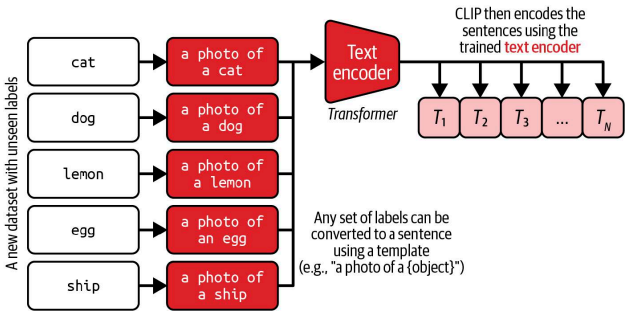
Contrastive pre-training

Un codificador de texto tipo Transformer convierte textos en **text embeddings** y un ViT actúa como codificador de imágenes para generar **image embeddings**. Luego, dado un lote de pares texto-imagen, se comparan todas las combinaciones posibles de embeddings usando similitud de coseno y se entrenan las redes para maximizar la puntuación entre pares texto-imagen coincidentes y minimizar la puntuación entre pares texto-imagen incorrectos.



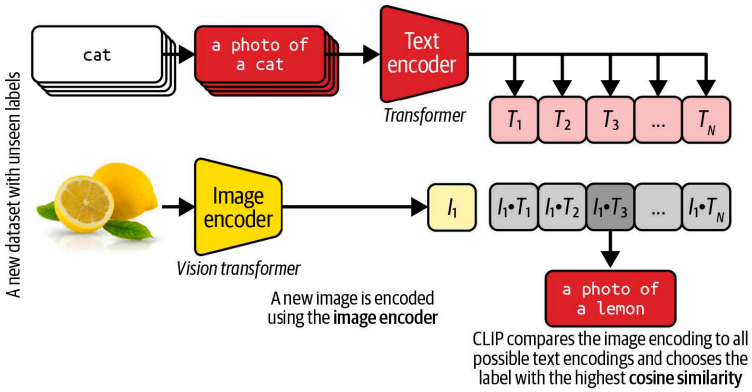
CLIP text embeddings

CLIP se puede utilizar para realizar predicciones "zero-shot" en tareas a las que nunca ha estado expuesto. Por ejemplo, podemos convertir las etiquetas de ImageNet en oraciones usando una plantilla como "una foto de un < etiqueta >".



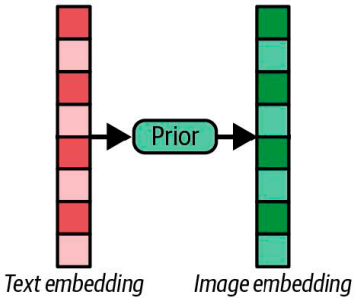
CLIP for zero-shot prediction

Para predecir la etiqueta de una imagen determinada, podemos pasarla a través del codificador de imágenes CLIP y calcular la similitud del coseno entre la incrustación de la imagen y todas las incrustaciones de texto posibles para encontrar la etiqueta con la puntuación máxima.



The Prior

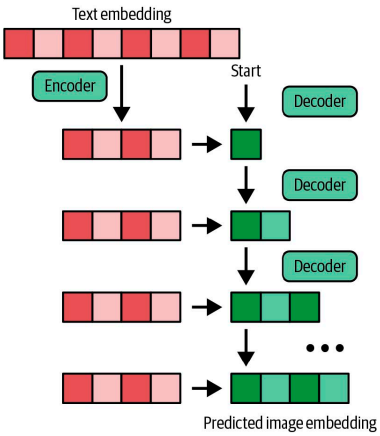
La siguiente etapa consiste en convertir el embedding de texto en embedding de imagen.



Los autores de DALL·E 2 probaron dos métodos diferentes para entrenar el modelo anterior: un modelo autorregresivo y un modelo de difusión. Descubrieron que el enfoque de difusión superaba al modelo autorregresivo y era más eficiente desde el punto de vista computacional.

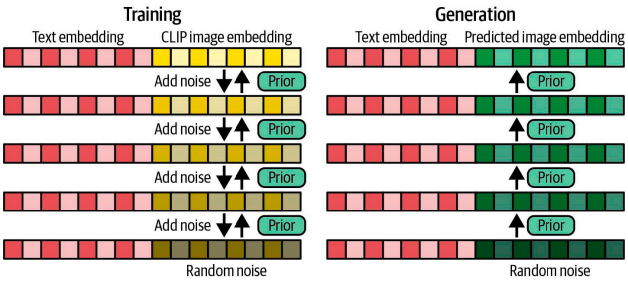
Autoregressive prior

El prior autorregresivo de DALL·E 2 es un Transformer codificador-decodificador, entrenado para reproducir el embedding de imagen dado el embedding de texto generado por CLIP.



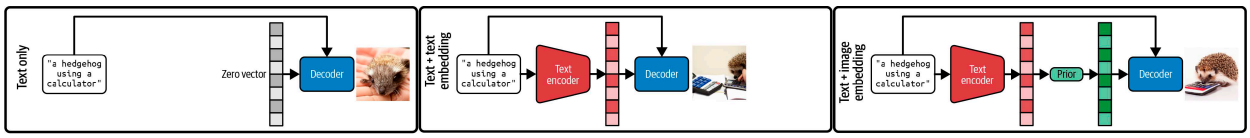
Diffusion prior

Como alternativa al prior autorregresivo, DALL·E 2 utiliza un Transformer de solo decodificación, entrenado mediante un proceso de difusión. Durante el entrenamiento, el embedding de texto y de imagen se concatenan en un único vector. Se aplica ruido al embedding de imagen hasta que no se puede distinguir. El diffusion prior se entrena para predecir el embedding de imagen sin ruido teniendo acceso al embedding de texto en todo momento, por lo que puede condicionar sus predicciones a esta información, transformando gradualmente el ruido aleatorio en un embedding de imagen.



Importance of the prior

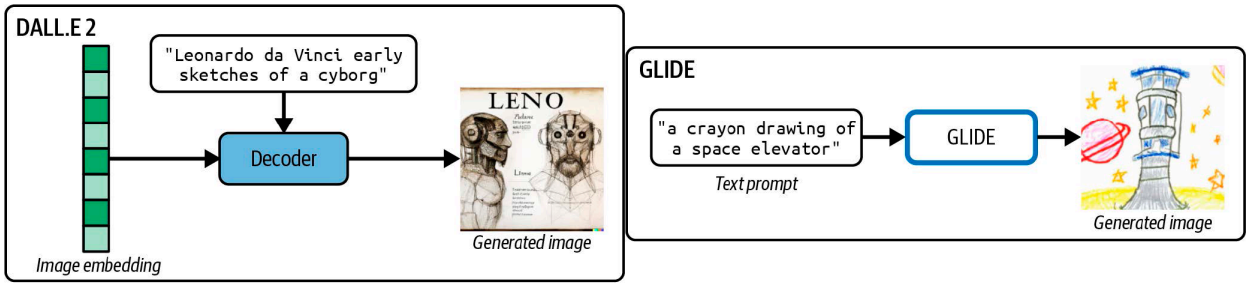
El propósito del prior es proporcionar al decodificador una representación útil de la imagen que se generará, haciendo uso del modelo CLIP previamente entrenado. Sin embargo, es factible que este paso no sea necesario; tal vez podríamos simplemente pasar el embedding de texto directamente al decodificador en lugar del embedding de imagen, o ignorar los embeddings de CLIP por completo. ¿Cómo impacta eso en la calidad de las generaciones?



The Decoder

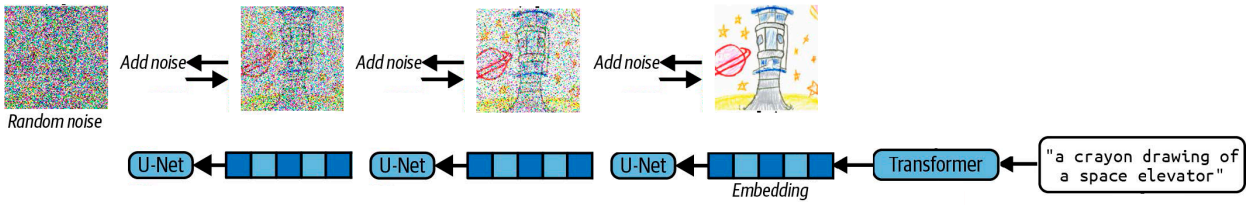
La parte final de DALL·E 2 es el decodificador que se encarga de generar la imagen final condicionada al prompt y al embedding de imagen proporcionado por el prior. DALL·E 2 usa el modelo "Guided Language to Image Diffusion for Generation and Editing" (GLIDE) como

decodificador. GLIDE fue entrenado desde cero para generar imágenes directamente a partir de prompts de texto, sin utilizar embeddings.



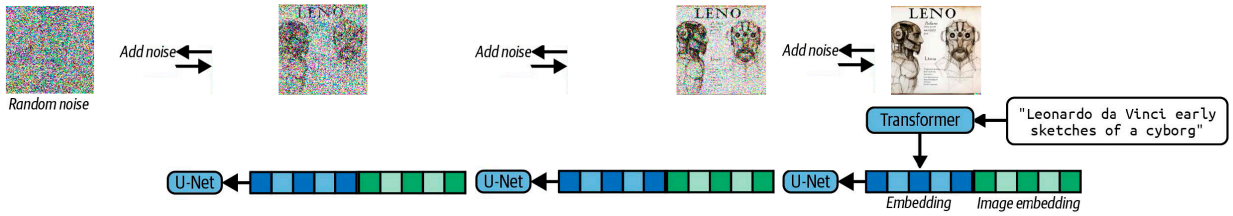
GLIDE

GLIDE está entrenado como modelo de difusión, con arquitectura U-Net para el eliminador de ruido y arquitectura Transformer para el codificador de texto. Aprende a deshacer el ruido agregado a una imagen, guiado por el prompt. Finalmente, se entrena un Upsampler para escalar la imagen generada.



The DALL·E decoder

El decodificador del DALL·E 2 también utiliza el Transformer como codificador de texto y U-Net para eliminación de ruido, pero además tiene los embeddings de imágenes calculados por CLIP anteriormente para condicionar.



Upsampler

La parte final del decodificador es el Upsampler (dos modelos de difusión separados). El primer modelo de difusión transforma la imagen de 64 × 64 a 256 × 256 píxeles. El segundo lo vuelve a transformar, de 256×256 a 1.024×1.024 píxeles. El muestreo ascendente es útil porque mejora la eficiencia al poder trabajar con imágenes pequeñas durante gran parte del proceso.

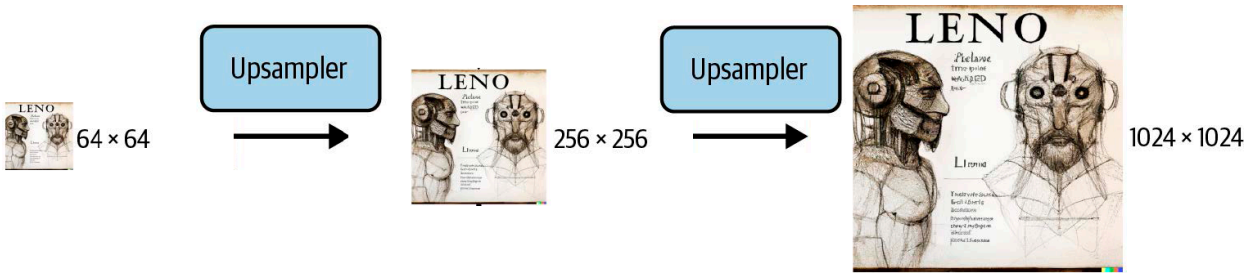
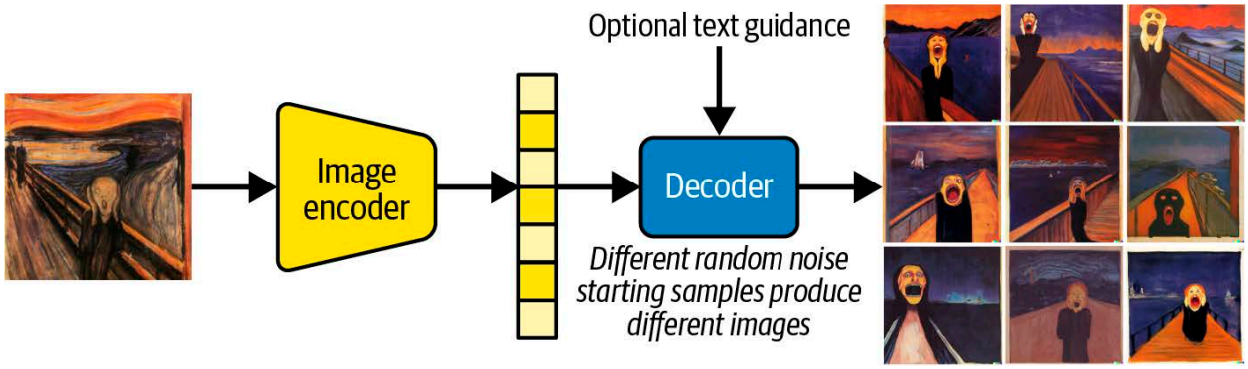


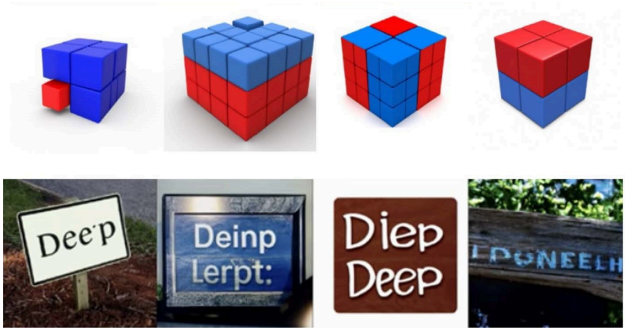
Image variations

Para generar imágenes usando el decodificador, DALL·E 2 toma muestras de una imagen que consiste en ruido aleatorio puro y luego reduce gradualmente la cantidad de ruido usando el modelo de difusión de eliminación de ruido, condicionado al embedding de imagen proporcionado. La selección de diferentes muestras de ruido aleatorio iniciales dará como resultado imágenes diferentes.



Limitations

DALL·E 2 presenta ciertas limitaciones asociadas a combinar atributos y generación de texto. Por ejemplo: “A red cube on top of a blue cube” y “A sign that says deep learning”:



In [2]:
```
from DallE import *
```

In [2]:
```
DALLE(model="dall-e-2", prompt="A Master Jedi Cat Holding A Light Saber")
```



In [3]:
```
DALLE(model="dall-e-2", prompt="A Master Jedi Cat Holding A Light Saber")
```



DALL·E 3

DALL·E 3 comprende muchos más matices y detalles que la versión anterior. Los autores construyeron un "image captioner" robusto para generar captions de imágenes altamente descriptivos y entrenaron el modelo con un 95% de datos sintéticos.

Cómo decodificador de imágenes, DALL·E 3 usa un modelo de difusión latente condicionado al texto con arquitectura U-Net. Se entrenó un decodificador de difusión propio sobre el espacio latente aprendido por el VAE. Esto mejoró mucho los detalles finos de la imagen, por ejemplo, texto y rostros humanos.

In [2]:
```
DALLE(model="dall-e-3", prompt="A Master Jedi Cat Holding A Light Saber")
```



In [ ]: